

Data vis practice5 - team2

22000245	문버리
22200788	한지석
22100826	아디 푸트라 알핀

사용 패키지

```
library(dplyr)
library(tidyr)
library(stringr)
library(ggplot2)
install.packages("openxlsx")
library(openxlsx)
```

이번 과제에서는 시각화 실습에서는 지역별(시도별) 소득 격차와 부동산 가격의 변화, 그리고 둘 사이의 상관관계를 시각화를 통해 표현해보려고 한다. 주어진 샘플 그래프들은 outdated dataset을 사용한 시각화 자료들이다. 제공된 데이터set을 활용하여 최신 정보를 시각화에 반영하여 update된 시각화 자료를 표현하여라. 한국 정부 데이터라 영어버전이 제공되지 않을 수 있는데, 팀메이트들이 외국인 학생들이 데이터나 정보를 잘 이해하고 번역할 수 있도록 도움을 주기 바랍니다.

```
reg <- read.xlsx("C:/Users/silkj/Desktop/한동대학교/5학기/데이터  
시각화/Data-Visualization/myRVis/지역총생산.xlsx") #지역 총생산  
데이터
```

```
house <- read.csv("C:/Users/silkj/Desktop/한동대학교/5학기/데이터  
시각화/Data-Visualization/myRVis/주택도시보증공사_전국 신규 민간  
아파트 분양가격 동향_20240731.csv",  
fileEncoding = "CP949")#아파트 분양가격 데이
```

터

```
Consumption <- read.csv("C:/Users/silkj/Desktop/한동대학교/5학기/데이터 시각화/Data-Visualization/myRVis/1인당_민간소비지출액_시도__20240927170852.csv",  
                        fileEncoding = "CP949")#민간소비지출액
```

데이터

```
Personal_income <- read.csv("C:/Users/silkj/Desktop/한동대학교/5학기/데이터 시각화/Data-Visualization/myRVis/1인당_개인소득_시도__20240927170417.csv",  
                             fileEncoding = "CP949")#개인소득
```

데이터

```
Gross_regional_income<- read.csv("C:/Users/silkj/Desktop/한동대학교/5학기/데이터 시각화/Data-Visualization/myRVis/1인당_지역총소득_시도__20240927170650.csv",  
                                   fileEncoding = "CP949")#지
```

역총소득 데이터

Task1. 2022년도 시도별 소득 데이터와 신규 아파트 분양가 시각화

데이터 전처리

```
apart<-reg%>%  
  select(X1, "2022")#지역총생산
```

결국 필요한 것은 소득에 대한 데이터와 함께 아파트의 분양가를 비교하는 것이므로 그를 위한 준비 시작, 지역 총생산 데이터에서 2022년도의 값들을 선택함

```
Consumption <- Consumption %>%  
  mutate(시도별 = gsub("전국", "전국", 시도별)) %>% # 서울의 경우  
  #에는 변환이 불필요할 수 있습니다.  
  mutate(시도별 = gsub("서울특별시", "서울", 시도별)) %>% # '강원도'  
  # -> '강원' 으로 변경  
  mutate(시도별 = gsub("부산광역시", "부산", 시도별)) %>%
```

```

mutate(시도별 = gsub("대구광역시", "대구", 시도별)) %>%
mutate(시도별 = gsub("인천광역시", "인천", 시도별)) %>%
mutate(시도별 = gsub("광주광역시", "광주", 시도별)) %>%
mutate(시도별 = gsub("대전광역시", "대전", 시도별)) %>%
mutate(시도별 = gsub("울산광역시", "울산", 시도별)) %>%
mutate(시도별 = gsub("세종특별자치시", "세종", 시도별)) %>%
mutate(시도별 = gsub("경기도", "경기", 시도별)) %>%
mutate(시도별 = gsub("강원특별자치도", "강원", 시도별)) %>%
mutate(시도별 = gsub("충청북도", "충북", 시도별)) %>%
mutate(시도별 = gsub("충청남도", "충남", 시도별)) %>%
mutate(시도별 = gsub("전북특별자치도", "전북", 시도별)) %>%
mutate(시도별 = gsub("전라남도", "전남", 시도별)) %>%
mutate(시도별 = gsub("경상북도", "경북", 시도별)) %>%
mutate(시도별 = gsub("경상남도", "경남", 시도별)) %>%
mutate(시도별 = gsub("제주특별자치도", "제주", 시도별)) # 제주특
별자치도 -> 제주

```

민간소비지출액 항목의 경우, 시도별 이라고 하는 변수의 값들이 이전 지역총생산의 값과 다르므로 값들을 일치시키는 작업 진행

```

Personal_income <- Personal_income %>%
  mutate(시도별 = gsub("전국", "전국", 시도별)) %>% # 서울의 경우
  #에는 변환이 불필요할 수 있습니다.
  mutate(시도별 = gsub("서울특별시", "서울", 시도별)) %>% # '강원
  #도' -> '강원' 으로 변경
  mutate(시도별 = gsub("부산광역시", "부산", 시도별)) %>%
  mutate(시도별 = gsub("대구광역시", "대구", 시도별)) %>%
  mutate(시도별 = gsub("인천광역시", "인천", 시도별)) %>%
  mutate(시도별 = gsub("광주광역시", "광주", 시도별)) %>%
  mutate(시도별 = gsub("대전광역시", "대전", 시도별)) %>%
  mutate(시도별 = gsub("울산광역시", "울산", 시도별)) %>%
  mutate(시도별 = gsub("세종특별자치시", "세종", 시도별)) %>%
  mutate(시도별 = gsub("경기도", "경기", 시도별)) %>%
  mutate(시도별 = gsub("강원특별자치도", "강원", 시도별)) %>%
  mutate(시도별 = gsub("충청북도", "충북", 시도별)) %>%
  mutate(시도별 = gsub("충청남도", "충남", 시도별)) %>%
  mutate(시도별 = gsub("전북특별자치도", "전북", 시도별)) %>%
  mutate(시도별 = gsub("전라남도", "전남", 시도별)) %>%

```

```
mutate(시도별 = gsub("경상북도", "경북", 시도별)) %>%
mutate(시도별 = gsub("경상남도", "경남", 시도별)) %>%
mutate(시도별 = gsub("제주특별자치도", "제주", 시도별)) # 제주특별자치도 -> 제주
```

```
Gross_regional_income <- Gross_regional_income %>%
mutate(시도별 = gsub("전국", "전국", 시도별)) %>% # 서울의 경우에는 변환이 불필요할 수 있습니다.
```

```
mutate(시도별 = gsub("서울특별시", "서울", 시도별)) %>% # '강원도' -> '강원' 으로 변경
```

```
mutate(시도별 = gsub("부산광역시", "부산", 시도별)) %>%
mutate(시도별 = gsub("대구광역시", "대구", 시도별)) %>%
mutate(시도별 = gsub("인천광역시", "인천", 시도별)) %>%
mutate(시도별 = gsub("광주광역시", "광주", 시도별)) %>%
mutate(시도별 = gsub("대전광역시", "대전", 시도별)) %>%
mutate(시도별 = gsub("울산광역시", "울산", 시도별)) %>%
mutate(시도별 = gsub("세종특별자치시", "세종", 시도별)) %>%
mutate(시도별 = gsub("경기도", "경기", 시도별)) %>%
mutate(시도별 = gsub("강원특별자치도", "강원", 시도별)) %>%
mutate(시도별 = gsub("충청북도", "충북", 시도별)) %>%
mutate(시도별 = gsub("충청남도", "충남", 시도별)) %>%
mutate(시도별 = gsub("전북특별자치도", "전북", 시도별)) %>%
mutate(시도별 = gsub("전라남도", "전남", 시도별)) %>%
mutate(시도별 = gsub("경상북도", "경북", 시도별)) %>%
mutate(시도별 = gsub("경상남도", "경남", 시도별)) %>%
mutate(시도별 = gsub("제주특별자치도", "제주", 시도별)) # 제주특별자치도 -> 제주
```

개인소득과 지역총소득에 대해서도 동일하게 진행함

```
Consumption_2022<-Consumption%>%
select(시도별, "X2022")
Personal_income_2022 <- Personal_income%>%
select(시도별, X2022.p.)
Gross_regional_income_2022 <- Gross_regional_income%>%
select(시도별, X2022)
```

이제 각 데이터프레임에서 2022년도의 값들만 선택


```
house_2022<-house%>%
  filter(규모구분 == "모든면적")%>%
  filter(연도 == 2022)%>%
  filter(월 == 1)%>%
  select("지역명", "분양가격.제공미터.")
```

```
apart_mer <- apart %>%
  left_join(Consumption_2022, by = c("X1" = "시도별"))%>%#1인
  당 소비지출액
  left_join(Personal_income_2022, by = c("X1" = "시도별"))%
  >%#1인당 개인소득
  left_join(Gross_regional_income_2022, by = c("X1" = "시도
  별"))%>%#1인당 지역총소득
  left_join(house_2022, by = c("X1" = "지역명"))#분양가격
```

하나의 데이터프레임에 병합함, 이로서 각 시도별 값들이 저장되게 됨.

```
ggplot(apart_mer, aes(x = X2022.x, y = 분양가격.제공미터., lab
el = X1)) +
  geom_point(color = "blue", size = 1) + # 산점도
  점 추가
  geom_text(vjust = -1, hjust = 1, size = 3) + # 각 점
  에 라벨 추가
  labs(title = "2022년 소비지출액과 분양가격 간의 관계",
        x = "2022년 1인당 소비지출액",
        y = "분양가격 (제공미터당)")
```


2022년 소비지출액과 분양가격 간의 관계



2022년도 1인당 소비지출액과 아파트 분양가격의 시각화, 역시나 분양가격은 서울이 압도적으로 높고, 제주, 부산, 광주 등 대체적으로 소비지출액과 분양가격이 비례한 경우가 많음, 다만 세종, 대전, 광주, 강원 등의 지역은 소비지출액에 비해서는 분양가격이 낮다는 인사이트도 될 수 있음

```
ggplot(apart_mer, aes(x = X2022.p., y = 분양가격.제곱미터., label = X1)) +
  geom_point(color = "blue", size = 1) + # 산점도 점 추가
  geom_text(vjust = -1, hjust = 1, size = 3) + # 각 점에 라벨 추가
  scale_x_log10() +
  labs(title = "2022년 소득과 분양가격 간의 관계",
        x = "2022년 1인당 개인소득",
        y = "분양가격 (제곱미터당)")
```

2022년 소득과 분양가격 간의 관계




이번에는 소비가 아닌 개인 소득과 분양가격에 대한 내용을 정리함. 일단 분양가격이야 이전과 거의 비슷한데, 이전의 그래프와 다른 점이 있다면, 울산의 소득이 서울과 비슷할 정도로 높다는 것, 그리고 제주의 소득이 생각보다 더 낮다는 점 등이 있음

```

apart_mer <- apart_mer %>%
  mutate(지역총생산 = as.numeric(gsub("[^0-9]", "", `2022`)))
%>% # '2022' 변수를 숫자로 변환하고 새 이름으로 지정
  select(-`2022`) # 기존의 '2022' 변수를 삭제

ggplot(apart_mer, aes(x = 지역총생산, y = 분양가격.제곱미터., label = X1)) +
  geom_point(color = "blue", size = 1) + # 산점도
  geom_text(vjust = -1, hjust = 1, size = 3) + # 각 점에 라벨
  scale_x_log10() +
  labs(title = "2022년 지역총생산과 분양가격 간의 관계",
        x = "2022년 지역총생산",
        y = "분양가격 (제곱미터당)")
  
```

2022년 지역총생산과 분양가격 간의 관계




울산의 개인소득이 상당히 높았는데, 이번에는 지역 전체의 생산과 함께 비교를 시도함.

서울보다도 경기권의 지역총생산이 더 높았음을 확인할 수 있음. 아무래도 수도권 인구밀집과 함께 서울로의 출퇴근하는 사람들이나 경제인구가 많기 때문에 경기도의 지역총생산이 높게 나온것이 아닌가 함, 그리고 울산의 지역 총 생산이 생각보다도 더 적은것도 알 수 있다.

```
ggplot(apart_mer, aes(x = X2022.y, y = 분양가격.제곱미터., label = X1)) +
  geom_point(color = "blue", size = 1) + # 산점도
  geom_text(vjust = -1, hjust = 1, size = 3) + # 각 점에 라벨
  scale_x_log10() +
  labs(title = "2022년 지역총소득과 분양가격 간의 관계",
        x = "2022년 지역총소득",
        y = "분양가격 (제곱미터당)")
```


2022년 지역총소득과 분양가격 간의 관계



마지막으로 지역의 총 소득을 나타냄.


이제 그래프를 하나로 합치기

```

apart_long <- apart_mer %>%
  pivot_longer(cols = c(X2022.p., 지역총생산, X2022.y, X2022.
x),
               names_to = "variable", values_to = "value")
# facet_wrap을 사용하여 여러 관계를 한 번에 시각화
ggplot(apart_long, aes(x = value, y = 분양가격.제곱미터., label = X1)) +
  geom_point(color = "blue", size = 1) + # 산점도 점
  추가
  geom_text(vjust = -1, hjust = 1, size = 3) + # 각 점에
  라벨 추가
  scale_x_log10() + # X축 로그
  스케일 사용
  labs(title = "2022년 소득과 분양가격 간의 관계",
        x = "소득 (단위 천원)",
        y = "분양가격 (제곱미터당)") +

```

```
facet_wrap(~ variable, scales = "free_x") # 변수별로  
그래프 분리
```




```
house_2022 <- house_2022 %>%  
  mutate(권역 = case_when(  
    지역명 %in% c("서울", "인천", "경기") ~ "수도권",  
    지역명 %in% c("부산", "대구", "울산", "경북", "경남") ~ "영남  
권",  
    지역명 %in% c("광주", "전북", "전남") ~ "호남권",  
    지역명 %in% c("대전", "충북", "충남", "세종") ~ "충청권",  
    지역명 %in% c("강원") ~ "강원권",  
    지역명 %in% c("제주") ~ "제주권"  
  ))  
  
ggplot(house_2022, aes(x = reorder(지역명, 분양가격.제곱미터.),  
y = 분양가격.제곱미터., fill = 권역)) +
```

```

geom_col() +
geom_text(aes(label = 분양가격.제곱미터.), hjust = -0.1) +
# 텍스트 추가
scale_fill_brewer(palette = "Set3") + # 권역별 색상 설정
labs(title = "2022년 평균 신규아파트 분양가 (시/도별)",
      x = NULL,
      y = "분양가격 (제곱미터당)") +
coord_flip()

```



각 권역별로 색상의 차이를 두고, 분양가격을 정렬함

```


house_2022%>%
  group_by(권역, 분양가격.제곱미터.)%>%
  ggplot(aes(x = reorder(지역명, 분양가격.제곱미터.), y = 분양가
    격.제곱미터., fill = 권역)) +
  geom_col() +
  geom_text(aes(label = 분양가격.제곱미터.), hjust = -0.1) +
# 텍스트 추가
scale_fill_brewer(palette = "Set3") + # 권역별 색상 설정
labs(title = "2022년 평균 신규아파트 분양가 (시/도별)",

```

```

x = NULL,
y = "분양가격 (제곱미터당)" +
coord_flip()+ # 간결한 테마 적용
facet_wrap(~ 권역, ncol = 1, scales = "free_y", strip.position = "right")+
theme(
  strip.text.y = element_text(size = 5, angle = 0),
  panel.grid.major = element_blank(), # 주요 그리드 라인 제거
  panel.grid.minor = element_blank(), # 작은 그리드 라인 제거
  legend.position = "none" # 범례 제거
)

```



시도/권역별 신규 아파트 분양가격의 변화

```

house_2224 <- house %>%
  filter(규모구분 == "모든면적") %>%
  filter(연도 >= 2020) %>%

```

```

select("지역명", "분양가격.제곱미터.", 연도, 월) %>%
mutate(권역 = case_when(
  지역명 %in% c("서울", "인천", "경기") ~ "수도권",
  지역명 %in% c("부산", "대구", "울산", "경북", "경남") ~ "영남권",
  지역명 %in% c("광주", "전북", "전남") ~ "호남권",
  지역명 %in% c("대전", "충북", "충남", "세종") ~ "충청권",
  지역명 %in% c("강원") ~ "강원권",
  지역명 %in% c("제주") ~ "제주권"
)) %>%
mutate(날짜 = as.Date(paste(연도, 월, "01", sep = "-"), format = "%Y-%m-%d"))

```

시계열 데이터를 추가한 후, 시계열 데이터를 정리

```

house_labels <- house_2224 %>%
  group_by(지역명) %>%
  slice(1)


```

마킹을 위한 정리 후

```

ggplot(house_2224, aes(x = 날짜, y = 분양가격.제곱미터., color = 지역명, group = 지역명)) +
  geom_line(linewidth = 1) + # 선 그래프의 두께 설정
  facet_wrap(~ 권역, ncol = 1, scales = "free_y", strip.position = "right") +
  geom_text(data = house_labels, aes(label = 지역명), hjust = -0.1)
  geom_point(size = 1) + # 각 포인트 표시
  labs(title = "시간에 따른 지역별 분양가격 추이",
       x = "날짜",
       y = "분양가격 (제곱미터당)") +
  theme_minimal() +
  theme(legend.position = "none")

```



날짜에 따른 분양가격 변화를 체크

Task 4: Additionally, try to visualize the correlation between regional income/production disparities and regional real estate price changes. Explain what can be inferred from the visualization.

```
# Step 1: Filter the data for the year 2022
correlation_data_2022 <- subset(correlation_data, 연도 == 2022)

# Step 2: Ensure that '1인당 개인소득' and '총_분양가격' columns are numeric
correlation_data_2022$`1인당 개인소득` <- as.numeric(correlation_data_2022$`1인당 개인소득`)
correlation_data_2022$총_분양가격 <- as.numeric(correlation_data_2022$총_분양가격)


# Step 3: Check if there are any NA values after conversion
correlation_data_2022 <- na.omit(correlation_data_2022)

# Step 4: Calculate the correlation between '1인당 개인소득' and '총_분양가격'
```

```
correlation_value_2022 <- cor(correlation_data_2022$`1인당 개인

correlation_plot_2022 <- ggplot(correlation_data_2022, aes(x =
  geom_point(size = 3, alpha = 0.7) + # Plot points for each
  geom_smooth(method = "lm", se = FALSE, color = "black") +
  geom_text(aes(label = 시도별), hjust = -0.1, vjust = 0.5, size = 10) +
  labs(title = "Correlation Between Regional Income and Real Estate Price",
    x = "Per Capita Income (1인당 개인소득)",
    y = "Total Apartment Prices (총 분양가격(제곱미터))") +
  theme_minimal(base_family = "NanumGothic") + # Use a Korean font
  theme(plot.title = element_text(hjust = 0.5), # Center the title
    legend.position = "bottom") + # Move the legend to the bottom
  annotate("text", x = Inf, y = Inf, label = paste("Correlation (2022):",
    hjust = 1.1, vjust = 2, size = 5, color = "red", fontweight = "bold"))

# Step 6: Print the updated plot with correlation value for 2022
print(correlation_plot_2022)
```



The correlation coefficient is **0.46**, which is a **moderate positive correlation**. This suggests that there is a somewhat consistent relationship between higher per capita income and higher apartment prices. However, the correlation is not

very strong, indicating that other factors likely influence apartment prices besides income alone.

- **Higher-priced regions:** A few regions (like the blue cluster at the top right) indicate higher prices even when the per capita income is higher. This could represent more expensive regions such as Seoul, which generally have elevated housing costs due to factors like demand, population density, and limited space.
- **Mid-income, mid-price clusters:** There is a dense clustering of points in the middle range of income (~22,000–23,000) with a wide range of apartment prices (~20,000–30,000). This indicates that in some regions, per capita income is not a strong predictor of real estate prices, potentially due to other factors such as government policies, investment opportunities, or regional economic conditions.

Jeju's combination of **external demand** (from mainland buyers and foreign investors), **limited land supply**, and its role as a prime **tourist destination** contribute to high housing prices, despite the relatively low local incomes. This disparity highlights the complexities of real estate markets, where factors such as investment, tourism, and development restrictions can lead to housing price inflation that doesn't align with the economic conditions of the local population.

```
install.packages("ggiraphExtra")
library(readxl)
library(ggiraphExtra)

require(Kormaps)
require(tmap)
options(repos = c(CRAN = "https://cloud.r-project.org"))
install.packages("stringi")
install.packages("devtools")
devtools::install_github("cardiomoon/kormaps2014")
library(kormaps2014)

# Rename specific columns in the data frame
colnames(kormap1)[colnames(kormap1) == "name"] <- "시도별"
```



```

# Filter the merged data for the year 2022
correlation_data_2022 <- subset(correlation_data, 연도 == 2022)

# Merge the filtered data with the geographic data
merged_data_2022 <- merge(kormap1, correlation_data_2022, by = "region")

# Plot the map for per capita income in 2022
income_map_2022 <- ggplot(merged_data_2022, aes(x = long, y = lat)) +
  geom_polygon(color = "black") + # Add black borders to regions
  coord_fixed(1.3) + # Fix aspect ratio
  scale_fill_continuous(low = "lightgreen", high = "darkgreen",
                        name = "Per Capita Income (2022)") +
  labs(
    title = "Per Capita Income by Region (2022)",
    subtitle = "Data from Regional Income Statistics (2022)",
    caption = "Source: Korean Regional Dataset"
  ) +
  theme_minimal() +
  theme(
    axis.text = element_blank(),
    panel.grid = element_blank(),
    plot.title = element_text(size = 16, face = "bold"),
    plot.subtitle = element_text(size = 12),
    legend.title = element_text(size = 12)
  )

# Plot the map for total apartment prices in 2022
apartment_price_map_2022 <- ggplot(merged_data_2022, aes(x = long, y = lat)) +
  geom_polygon(color = "black") + # Add black borders to regions
  coord_fixed(1.3) + # Fix aspect ratio
  scale_fill_continuous(low = "lightblue", high = "darkblue",
                        name = "Total Apartment Prices (2022)") +
  labs(
    title = "Total Apartment Prices by Region (2022)",
    subtitle = "Data from Regional Real Estate Prices (2022)",
    caption = "Source: Korean Regional Dataset"
  )


```

```

) +
theme_minimal() +
theme(
  axis.text = element_blank(),
  panel.grid = element_blank(),
  plot.title = element_text(size = 16, face = "bold"),
  plot.subtitle = element_text(size = 12),
  legend.title = element_text(size = 12)
)

# Display both maps side by side
grid.arrange(income_map_2022, apartment_price_map_2022, ncol = 2)

```



We can further improve the visualization as we can show in the map, in the darker area we can further see that there is a correlation with earnings and housing prices, such as Seoul and Busan.

Income vs. Housing Prices: The maps show a general trend where regions with higher incomes also tend to have higher apartment prices. This is evident in Seoul and its surrounding areas, where both income and housing prices are high. However, the contrast is notable in regions like Jeju, which has lower income levels but still shows relatively high apartment prices, indicating a mismatch likely driven by tourism and external real estate demand rather than local income levels.