

Data vis practice6 -team2

(KOR) 다음 kaggle datasets 중 하나 (혹은 하나 이상)을 선택하여, 3개에서 5개 사이의 explanatory data visualization을 수행하고, 시각화를 통한 story telling(중요!)을 하여라. (필요하면 추가적인 데이터를 활용할 수 있다)

<Assume>

1. 유튜브 조회수와 stream간의 상관관계, 유튜브 조회수가 높은 상위 그룹이 stream도 높을 것이다?
2. stream이 높은 것들에 대한 음악성 평가 energy, speechness, acousetiness등을 통해 이러한 것들과 stream사이의 비교를 통해, 대중적으로 인기있는 음악은 무엇인지 확인
3. 한국인만 뽑아서, 지표를 찾아보기. → 한국 시장? 혹은 K pop의 위치 등등?

한국인 찾기

```
spo <- read.csv("C:/Users/silkj/Desktop/한동대학교/5학기/데이터 시각화/Data-Visualization/myRVis/Spotify_Youtube.csv")
```

```
spt_Artist<-spo %>%  
  group_by(Artist)%>%  
  select(Artist)%>%  
  distinct()  
print(spt_Artist)
```

```
# Artist 열을 벡터로 추출  
artist_vector <- spt_Artist %>% pull(Artist)
```

```
# 모든 값을 심표로 묶어서 하나의 문자열로 변환
```

```
artist_string <- paste(artist_vector, collapse = ", ")
```

```
# 결과 출력
```

```
artist_string
```

이제 나온 결과를 Chat-GPT를 활용해 한국인 아티스트를 추출하자,

Arcane, Sleepy Penguin, Stars Music Chile, AYLIVA, NewJeans, Grupo Frontera, Jung Kook, LE SSERAFIM, ThxSoMch, SICK LEGEND"
한국인 솔로 가수나, 한국인 아티스트를 뽑아줘



주어진 긴 리스트에서 한국인 솔로 가수 또는 한국인 아티스트를 추출하기 위해서는 주로 알려진 한국 가수와 그룹 이름들을 필터링해야 합니다. 아래는 그중 한국 가수와 아티스트들만 추출한 결과입니다.


한국인 솔로 가수 및 그룹:

- BTS
- EXO
- BLACKPINK
- TWICE
- Stray Kids
- Red Velvet
- NCT
- SEVENTEEN
- BIGBANG
- SHINee
- (G)I-DLE
- ATEEZ
- TOMORROW X TOGETHER (TXT)
- ENHYPEN
- IVE
- LE SSERAFIM
- NewJeans
- TAEYANG (빅뱅 태양)
- RM (BTS 멤버)
- Jimin (BTS 멤버)
- j-hope (BTS 멤버)
- Tz da Coronel
- IU (아이유)
- Girls' Generation (소녀시대)
- JAY PARK (박재범)
- ITZY

이 아티스트들은 모두 한국 출신으로, 솔로 가: ↓ 거나 그룹 멤버입니다.

이제 한국인 아티스트에 대해서, 스트리밍 평균을 구해서 시각화 해보자.

```
ko_sty %>%
  group_by(Artist) %>%
  summarise(average_stream = mean(Stream, na.rm = TRUE)) %
>%
  ggplot(aes(x = Artist, y = average_stream)) +
  geom_bar(stat = "identity") +
  theme(axis.text.x = element_text(angle = 45, hjust = 1))
# x축 텍스트를 45도 기울임
```



한국 아티스트들의 평균 stream수를 그래프로 나타내었다, jimin과 NewJeans의 경우 값이 NA값이기에 측정하지 못하였다.


이번에는 유튜브 조회수와 stream평균 수를 시각화 해 보겠다.

```
ko_sty_summary <- ko_sty %>%
  group_by(Artist) %>%
  summarise(average_stream = mean(Stream, na.rm = TRUE),
            average_views = mean(Views, na.rm = TRUE)) %>%
```

```
gather(key = "Metric", value = "Value", average_stream, a
verage_views)
```

두개의 평균을 구한 후

```
# 시각화
ggplot(ko_sty_summary, aes(x = Artist, y = Value, fill = Me
tric)) +
  geom_bar(stat = "identity", position = "stack") + # 겹치
는 방식으로 설정
  labs(y = "Value (Stream/Views)", title = "Comparison of A
verage Stream and Views") +
  theme(axis.text.x = element_text(angle = 45, hjust = 1))
# x축 레이블을 45도 기울임
```



평균 유튜브 조회수가 전체적으로 stream과 비슷한 수치를 보인다.

물론 평균치를 계산하였기 때문에, 이 경향이 정확할 것인가는 검증이 필요해 보인다. 이번에는 특정 그룹에 대해 stream과 유튜브 view를 비교해 보겠다.

```

ko_sty_IU <- ko_sty %>%
  filter(Artist == "IU") %>%
  select(Title, Stream, Views) %>%
  # Title을 짧게 지정할 수 있도록 새 열 생성
  mutate(Short_Title = case_when(
    Title == "[MV] IU(아이유)_LILAC(라일락)" ~ "라일락",
    Title == "[MV] IU(아이유) _ eight(에잇) (Prod.&Feat. SUGA
of BTS)" ~ "에잇",
    Title == "[MV] IU(아이유) _ BBIBBI(삐삐)" ~ "삐삐",
    Title == "[MV] IU(아이유) _ Blueming(블루밍)" ~ "블루밍",
    Title == "IU & Oh Hyuk - Can't Love You Anymore | 아이유
& 오혁 - 사랑이 잘 [Yu Huiyeol's Sketchbook / 2017.07.26]" ~
"사랑이 잘",
    Title == "[MV] IU(아이유) _ Celebrity" ~ "Celebrity",
    Title == "[MV] IU(아이유) _ strawberry moon" ~ "strawber
ry moon",
    Title == "[MV] IU(아이유) _ Palette(팔레트) (Feat. G-DRAGO
N)" ~ "Palette",
    Title == "[MV] IU(아이유) _ Through the Night(밤편지)" ~
"밤편지",
    Title == "IU (아이유) _ Good Day (좋은 날) _ MV" ~ "좋은
날",
    Title == "IU (아이유) _ Good Day (좋은 날) _ MV" ~ "좋은
날",
    TRUE ~ Title # 나머지 곡은 원래 제목 사용
  )) %>%
  gather(key = "Metric", value = "Value", Stream, Views)


```

```

ggplot(ko_sty_IU, aes(x = Short_Title, y = Value, fill = Me
tric)) +
  geom_bar(stat = "identity", position = "dodge") + # 막대
그래프 나란히 배치
  labs(title = "Comparison of Stream and Views for Each Son
g by IU",
    y = "Value (Stream/Views)", x = "Song Title") +

```

```
theme(axis.text.x = element_text(angle = 45, hjust = 1))
# x축 텍스트 기울임
```



유튜브 조회수보다 스트리밍 수가 더 높을 것이라는 예상과 다르게, 몇몇 노래들은 오히려 유튜브 뮤직 수가 더 높은것을 확인할 수 있었다.

이제 이 아티스트들을 하나의 벡터로 만들어 전체 데이터프레임에서 한국인 아티스트만을 추출하자

```
korean_artists <- c("BTS", "EXO", "BLACKPINK", "TWICE", "Stray Kids", "Red Velvet", "NCT",
                    "SEVENTEEN", "BIGBANG", "SHINee", "(G)I-DLE", "ATEEZ", "TOMORROW X TOGETHER",
                    "ENHYPEN", "IVE", "LE SSERAFIM", "NewJeans", "TAEYANG", "RM", "Jimin",
                    "j-hope", "IU", "Girls' Generation", "JAY PARK", "ITZY")
```

```
ko_sty<-spo %>%
  filter(Artist %in% korean_artists)
```


```
library(reshape2)
library(ggplot2)

# Select only numeric columns from the dataset
numeric_data <- music_data %>% select_if(is.numeric)

# Correlation matrix
cor_matrix <- cor(numeric_data, use = "complete.obs")

# Melt the correlation matrix for use in ggplot
melted_cor_matrix <- melt(cor_matrix)

# Plot heatmap using ggplot2
ggplot(data = melted_cor_matrix, aes(x = Var1, y = Var2, fill = value)) +
  geom_tile() +
  scale_fill_gradient2(low = "blue", high = "red", mid = "white",
    midpoint = 0, limit = c(-1, 1), space = "Lab",
    name = "Correlation") +
  theme_minimal() +
  theme(axis.text.x = element_text(angle = 45, vjust = 1, hjust = 1)) +
  coord_fixed()
```



각 변수들에 대해서 heatmap을 작성하였다. 우리가 중요하게 생각하는 stream이나, views와는 뚜렷한 경향을 보일만한 변수가 없었다.

```
# 새로운 열 추가: YouTube 수익 (Revenue from YouTube Views)
music_data <- music_data %>%
  mutate(
    YouTube_Revenue = ifelse(Views <= 10000, Views * 0.06,
    Views * 0.12)
  )

# 새로운 열 추가: Spotify 수익 (Revenue from Spotify Streams)
music_data <- music_data %>%
  mutate(
    Spotify_Revenue = Stream * (0.04 / 10) # 10스트리밍 당
    $0.04 계산
  )

# YouTube와 Spotify의 총 수익 계산
```

```
music_data <- music_data %>%
  mutate(
    Total_Revenue = YouTube_Revenue + Spotify_Revenue
  )

# 결과 확인
head(music_data %>% select(Track, Artist, Views, Stream, Yo
uTube_Revenue, Spotify_Revenue, Total_Revenue))
```

우리는 각 artist의 music별로 성과의 비교를 하기 위한 기준으로, youtube와 Spotify의 수익을 계산하여 revenue로 변경하였다.

```
# Install and load required library for sorting
library(dplyr)

# 가수별로 수익 합산 및 Top 10 추출
top_artists <- music_data %>%
  group_by(Artist) %>%
  summarise(Total_Revenue = sum(Total_Revenue, na.rm = TRU
E)) %>%
  arrange(desc(Total_Revenue)) %>%
  top_n(10, Total_Revenue)
```

```
# 결과 확인
print(top_artists)
# A tibble: 10 × 2
  Artist                                Total_Revenue
  <chr>                                <dbl>
1 Ed Sheeran                          1912804459.
2 CoComelon                          1753676874.
3 Katy Perry                          1600905164.
4 Charlie Puth                        1488276050.
5 Luis Fonsi                         1415590869.
6 Justin Bieber                      1367318298.
7 Daddy Yankee                      1325173071.
8 Bruno Mars                         1272501759.
```


9	Coldplay	1246787259.
10	Macklemore & Ryan Lewis	1230578581.

이제 가수별로 수익을 계산하여 상위 10명을 추출하였다.

```
# Load ggplot2
library(ggplot2)

# Create a combined dataset for both Danceability and Energy
combined_data <- top_singer_data %>%
  select(Artist, Total_Revenue, Danceability, Energy) %>%
  pivot_longer(cols = c(Danceability, Energy), names_to =
    "Attribute", values_to = "Value")

# Plot for Danceability
ggplot(combined_data %>% filter(Attribute == "Danceability"), aes(x = Total_Revenue, y = Value, color = Artist, group = Artist)) +
  geom_line(size = 1) + # Line plot
  geom_point(size = 2) + # Points on the line
  labs(title = "Danceability vs Total Revenue", x = "Total Revenue", y = "Danceability") +
  theme_minimal() +
  theme(legend.title = element_blank())
```




상위 10명 가수에 대한 곡 Danceability과 Revenue를 계산해 보았다.

댄스 가능성에서 댄스 가능성 및 총 수익과 큰 상관관계가 있음을 알 수 있다.

cocomelon 노래와 같이 춤추기 쉬운 노래일수록 조회수, 좋아요, 댓글이 많다.

1. cocomelon의 경우 아이들이 노래에 맞춰 춤을 출 수 있어야 하고, 계속 재미있게 즐길 수 있는 것이 중요합니다.
2. 다른 노래의 경우 클럽, 콘서트 또는 기타 장소에서 노래를 사용할 수 있을 때 많은 수익을 창출합니다.

```
# Plot for Energy
ggplot(combined_data %>% filter(Attribute == "Energy"), aes
(x = Total_Revenue, y = Value, color = Artist, group = Artist)) +
  geom_line(size = 1) + # Line plot
  geom_point(size = 2) + # Points on the line
  labs(title = "Energy vs Total Revenue", x = "Total Revenue", y = "Energy") +
  theme_minimal() +
  theme(legend.title = element_blank())
```



곡의 Energy와 Revenue를 계산해 보았다.

Energy가 높은 곡들이 더 많이 듣게되고, Revenue가 높게 책정되는 것 같다. 그러나 너무 많은 에너지가 분산되어 혼란을 일으킬 수 있기 때문에 춤추는 것만큼 높지는 않고, 그래서 수익성이 가장 많은 수익을 창출하는 0.6 정도이다.

```
# Create a combined dataset for all relevant attributes
combined_data <- top_singer_data %>%
  select(Artist, Total_Revenue, Key, Loudness, Speechiness,
    Acousticness, Instrumentalness, Liveness, Valence, Tempo, Duration_ms, Views, Likes, Comments, Stream) %>%
  pivot_longer(cols = c(Key, Loudness, Speechiness, Acousticness, Instrumentalness, Liveness, Valence, Tempo, Duration_ms, Views, Likes, Comments, Stream),
    names_to = "Attribute", values_to = "Value")

# Create a list of attributes to plot
attributes_to_plot <- c("Key", "Loudness", "Speechiness",
  "Acousticness",
  "Instrumentalness", "Liveness", "Valence",
```

```


        "Tempo", "Duration_ms", "Views",
        "Likes", "Comments", "Stream")

# Loop through each attribute and create plots
for (attribute in attributes_to_plot) {
  p <- ggplot(combined_data %>% filter(Attribute == attribute),
             aes(x = Total_Revenue, y = Value, color = Artist, group = Artist)) +
    geom_line(size = 1) + # Line plot
    geom_point(size = 2) + # Points on the line
    labs(title = paste(attribute, "vs Total Revenue"), x =
"Total Revenue", y = attribute) +
    theme_minimal() +
    theme(legend.title = element_blank())

  print(p) # Print each plot
}


```

이제 다양한 변수들과 total Revenue의 비교를 수행하자




Loudness와 Total Revenue의 경우에는 음악의 볼륨이 -5.0 ~ -7.5사이로 수렴하려는 경향이 많이 보이며 대부분의 곡들이 이 부분에 위치해 있다. 에너지와 마찬가지로 노래 소리

가 클수록 청각에 더 큰 방해가 되고 청력을 손상시킬 수 있다. 따라서 이 경우에는 음량을 낮출수록 수익성이 높아진다.




speechiness

speechiness는 0.1 미만의 값에서 total Revenue가 위치해 있다. 총 수익 측면에서 가장 성공적인 트랙은 가사가 적은 경향이 있으며, 이는 음악이 많고 가사가 적은 노래가 더 높은 수익을 창출하는 경향이 있음을 의미한다. 아동용 콘텐츠를 제작하는 것으로 보이는 CoComelon은 콘텐츠의 특성으로 인해 일관되게 높은 말투를 보이는 다른 패턴을 보인다.




라이브에 관련해서는 라이브가 많으면 순위가 높지 않을까 예상했으나, 의외로 가장 많은 income을 가져온 곡들은 liveness가 적었다. 즉 밴드보다는 포로듀싱된 노래들이 더 높았다. 생동감 값이 높은 트랙은 전반적으로 수익이 낮은 것으로 보이며, 이는 라이브 녹음이 일반적으로 스튜디오 녹음만큼 주류가 아니거나 다들 어지지 않아 대중에게 어필할 가능성이 낮기 때문일 수 있다. 총 수익 측면에서 가장 성공적인 트랙은 일반적으로 생동감이 낮는데, 이는 스튜디오에서 녹음하고 다듬은 트랙이 상업적으로 더 성공적이라는 것을 의미한다.




벨런스와 total Revenue에 대해서도 0.75선으로 수렴하고 있다. 수익성이 높은 음악들은 valance가 0.5이상이어야 한다. 단, 추세만으로는 0.6에서 만들어지지만, 실제 total Revenue가 높은 값을 확인해보면 valance가 0.75 이상의 값을 가진다


이 차트는 높은 빈도(행복한 노래)와 낮은 빈도(슬픈 노래) 모두 상업적으로 성공할 수 있음을 말하는데, 모든 아티스트의 조회수와 총 수익 사이에는 직접적인 상관관계가 없고 아티스트별 트렌드: cocomelon과 같은 일부 아티스트는 높은 빈도의 경쾌한 노래를 제작할 가능성이 높은 반면, 콜드플레이나 에드 시런과 같은 아티스트는 성공적인 포트폴리오에 행복한 노래와 슬픈 노래를 모두 섞어 제작하지만 total Revenue가 크게 차이가 나지 않는다.




음악의 템포에 따라서는 정확히 높고 낮음에 따라 비용이 수렴하지 않고 개개인의 취향에 따라 다를 것 같다. 실제 top 10데이터상에서 total Revenue는 특정 템포로 모이지 않고 각기 다른 스타일로 적용되고 있다.




음악의 시간은 total revenue가 한쪽으로 모이는 값이 분명한 것 같다. 200초~250초 사이에 많은 값들이 모여서 이 시간대의 음악이 가장 많은 인기를 가진다. 따라서 국제적 추세도 3분~4분 초반대로 모이는 것 같다.




유튜브의 조회수별 total Revenue의 값은 같은 추세를 보인다. 조회수에 따라 수익이 발생하기 때문이다.



likes역시 그 수에 따라 total Revenue가 높 나타난다.



댓글은 참여도를 반영하지만 항상 수익을 반영하지는 않는다. 댓글과 총 수익 사이에는 양의 상관관계가 있지만, 좋아요만큼 관계가 강하지는 않는데, 이는 팬의 행동이 다르기 때문일 수도 있다. 어떤 트랙은 많은 토론을 유발하는 반면, 어떤 트랙은 대규모 토론을 유발하지 않아도 스트리밍이나 구매가 더 많이 이루어질 수 있다. 이상치로서의 저스틴 비버의 댓글이 급증한 것은 해당 곡에서 네티즌들이 저스틴 비버의 노래에 대해 갑론을박을 벌였기 때문에 발생하였다.



이번에는 스포티파이에서 stream된 수와 Revenue를 비교해 보았다. 스포티파이의 조회수가 Revenue에 직접적인 영향을 주기 때문에 당연히 오르지 않을까 했는데, 몇몇 경우에서 한 점으로 수렴하는 것을 확인하였다. 이는 스포티파이의 stream값이 제한이 있는것이 아닐까 생각할수있다.

Korean vs Global Artist

```
korean_avg_attributes <- korean_singer_data %>%
  summarise(across(c(Danceability, Energy, Key, Loudness, Spe
    Instrumentalness, Liveness, Valence, Tem
    mean, na.rm = TRUE)))
```

```

global_avg_attributes <- Spotify_Youtube %>%
  summarise(across(c(Danceability, Energy, Key, Loudness, Spe
                    Instrumentalness, Liveness, Valence, Tem
                    mean, na.rm = TRUE)))

comparison_data <- bind_rows(
  korean_avg_attributes %>%
    mutate(Artist_Type = "Korean Artists"),
  global_avg_attributes %>%
    mutate(Artist_Type = "Global Artists")
)

# Pivot the data for easier comparison
comparison_data_long <- comparison_data %>%
  pivot_longer(cols = -Artist_Type, names_to = "Attribute", v

# Pivot the data for faceted plotting
comparison_data_long_faceted <- comparison_data %>%
  pivot_longer(cols = -Artist_Type, names_to = "Attribute", v

# Plot the faceted comparison between Korean artists and glob
ggplot(comparison_data_long_faceted, aes(x = Artist_Type, y =
  geom_bar(stat = "identity", position = "dodge") +
  facet_wrap(~ Attribute, scales = "free_y") + # Faceting by
  labs(
    title = "Comparison of Musical Attributes: Korean Artists
    x = "Artist Type",
    y = "Average Value"
  ) +
  theme_minimal() +
  scale_fill_manual(values = c("Korean Artists" = "blue", "Gl
  theme(axis.text.x = element_text(angle = 45, hjust = 1))

```

이제는 아까 위에서 선택한 한국 artist들에 대해서도 동일하게 시각화를 해보자

```

korean_artists <- c("BTS", "EXO", "BLACKPINK", "TWICE", "St
ray Kids", "Red Velvet", "NCT",

```

```

        "SEVENTEEN", "BIGBANG", "SHINee", "(G)I
-DLE", "ATEEZ", "TOMORROW X TOGETHER",
        "ENHYPEN", "IVE", "LE SSERAFIM", "NewJe
ans", "TAEYANG", "RM", "Jimin",
        "j-hope", "IU", "Girls' Generation", "J
AY PARK", "ITZY")

```

```

korean_singer_data <- music_data %>%
  filter(Artist %in% korean_artists) %>%
  arrange(Artist, desc(Total_Revenue)) #

```

#한국 가수들에 대한 내용

```

# Create a combined dataset for all relevant attributes
combined_data <- korean_singer_data %>%
  select(Danceability, Energy, Artist, Total_Revenue, Key,
Loudness, Speechiness, Acousticness, Instrumentalness, Live
ness, Valence, Tempo, Duration_ms, Views, Likes, Comments,
Stream) %>%
  pivot_longer(cols = c(Danceability, Energy, Key, Loudness,
Speechiness, Acousticness, Instrumentalness, Liveness, Vale
nce, Tempo, Duration_ms, Views, Likes, Comments, Stream),
              names_to = "Attribute", values_to = "Value")

```

```

# Create a list of attributes to plot
attributes_to_plot <- c("Danceability", "Energy", "Key", "Lo
udness", "Speechiness", "Acousticness",
                      "Instrumentalness", "Liveness", "Va
lence",
                      "Tempo", "Duration_ms", "Views",
                      "Likes", "Comments", "Stream")

```

```

# Loop through each attribute and create plots
for (attribute in attributes_to_plot) {
  p <- ggplot(combined_data %>% filter(Attribute == attribu
te),
              aes(x = Total_Revenue, y = Value, color = Art

```


```


ist, group = Artist)) +
  geom_line(size = 1) + # Line plot
  geom_point(size = 2) + # Points on the line
  labs(title = paste(attribute, "vs Total Revenue"), x =
"Total Revenue", y = attribute) +
  theme_minimal() +
  theme(legend.title = element_blank())

print(p) # Print each plot
}

```



<Energy>







에너지 항목에서, 한국의 에너지는 대부분 파워풀하고 그 값이 높은 편이지만, 해외에서는 조금더 다양한 energy경향을 보인다. 해외는 더 다양한 장르 및 energy가 있어서 우리나라도 조금 다양성을 높일 필요가 있다

<Loudness>



loudness에서는 한국의 경우 -5정도로 국제적 추세에 비해서 더 좁게 많이 모여있으며, 국제적인 추세에서는 훨씬 다양하고 더 낮거나, 높은 다양한 케이스가 존재한다



<Liveness>



liveness에서는

해외의 경우 오히려 라이브가 더 적은것으로 보이며, 그것도 비용에 따라 점점 줄어들고, 이는 밴드음악보다 프로듀싱된 음악이 많다는 것을 보여준다



<Views>



View와 Total Revenue는 완벽한 상향 그래프를 보여준다. 즉 유튜브를 통해 얻은 수익은 비례한다는 것을 의미한다.

그렇다면 우리팀의 예상은 Stream 또한 비례한 그래프를 보일 수 있는 것이었다.

<Stream>



하지만 우리와의 예상과 다르게 Stream은 매우 다양한 그래프를 보이고 있었다. Ed Sheeran과 Charlie Puth를 비교하면 Stream은 Ed Sheeran이 더 높지만 Total Revenue는 동일하다. 다시말해, 해외의 아티스트들은 유튜브를 통해 버는 수익이 좀 더 크다는 것을 알 수 있다. 더 나아가, 한국의 Stream-Total Revenue 그래프의 평균선이 해외의 평균선보다 더 가파르다는 것을 볼 수 있다. 즉, 한국은 아직 Stream의 수익에 유튜브의 수익보다는 조금 더 의존하고 있다고 볼 수 있다. 다시말해, 현재 해외에서 활동 중인 아티스트들이 유튜브 영상에도 노력을 많이 한다는 것을 알 수 있다.

```

library(tidyverse)
library(tm)
library(wordcloud)

# Filter videos with high views
high_view_videos <- music_data %>% filter(Views > quantile(
  Views, 0.75, na.rm = TRUE))
low_view_videos <- music_data %>% filter(Views > quantile(V
  iews, 0.25, na.rm = TRUE))

# Create corpus of titles
corpus <- Corpus(VectorSource(high_view_videos$Title))
corpus <- Corpus(VectorSource(high_view_videos$Title))

# Clean and tokenize titles
corpus_clean <- tm_map(corpus, content_transformer(tolowe
r)) %>%
  tm_map(removePunctuation) %>%
  tm_map(removeWords, stopwords("en")) %>%
  tm_map(removeNumbers) %>%
  tm_map(stripWhitespace)


# Create word cloud
wordcloud(corpus_clean, max.words = 100, random.order = FAL
SE)

```

그렇다면 많이 보이는 유튜브 영상의 title에서 가장 많이 사용된 단어들을 무엇인지 보기위
해 map으로 표현



아무래도 stream되는 음악들의 youtube title을 기준으로 사용했기 때문에, video, official, music등이 많이 사용된것 같다.



에너지와 loudness를 줄이고, liveness도 줄일수록 좋다.

위 그래프는 Top10의 해외 아티스트들과 비교한 것이 아닌 해외 모든 아티스트들과 한국 아티스트들 간의 비교를 한 것이다. 즉 해외 아티스트 모두의 평균을 구한 것으로 다시 말해 해외 음악 소비자들의 트렌드를 볼 수 있다는 것이다.

분석 결과 acoustiness, Instrumentalness은 한국이 좀 작고, danceability, energy, loudness은 크다. 미국은 밴드음악이 대중적이고, 한국은 Kpop으로서

Conclusion

Goal

We suggest to Korea team to be in the Bill Board, they should,

- Decrease Energy, loudness and liveness
- Focus on youtube more

A team that has just begun to expand overseas

- Increase acoustiness
- Decrease danceability, energy, loudness
- Increase Instrumentalness